

DOSSIÊ TÉCNICO

Investigação de captação líquida futura em fundos de ações com dados públicos da CVM

1. Objetivo

O objetivo deste trabalho foi investigar o que explica a captação líquida futura de entidades da classe Ações em funcionamento normal, usando exclusivamente dados públicos da CVM, e construir um pipeline reproduzível cobrindo ETL, features, validação temporal, baseline de modelagem e artefatos de análise.

O problema foi formulado como regressão, com target contínuo `flow_%` futuro, definido como fluxo líquido futuro acumulado entre T+1 e T+21 dias úteis, normalizado por PL defasado em 1 dia. A formulação em classificação, usando top-decile, foi mantida como extensão possível, mas não como abordagem principal.

2. Fontes de dados

Foram usadas apenas fontes públicas da CVM. A primeira foi o Informe Diário de Fundos, distribuído em arquivos mensais no formato `inf_diario_fi_YYYYMM.zip/csv`. A segunda foi o cadastro de classes, obtido a partir do arquivo `registro_fundo_classe.zip` e armazenado localmente como `registro_classe.csv`. Não foram usados datasets de terceiros.

3. Pipeline e reprodutibilidade

O pipeline foi organizado em seis etapas principais. A primeira faz o download dos arquivos de informe diário e do cadastro de classes. A segunda consolida o informe diário com o cadastro. A terceira aplica o recorte do case, trata calendário e constrói o target. A quarta executa a validação manual exigida no desafio. A quinta monta a base de features sem vazamento. A sexta treina e avalia o baseline temporal.

Os scripts principais do fluxo são:

download_csv.py

consolidar_csv.py

build_scope_dataset.py

validate_manual_samples.py

build_features_dataset.py

train_flow_baseline.py

Esse fluxo permite reproduzir o fluxo completo proposto para a resolução do case.

4. Mapa de dados e dicionário resumido

A unidade de análise adotada foi ENTITY_KEY = CNPJ_FUNDO + ID_SUBCLASSE. Essa escolha foi importante para evitar mistura de subclasses distintas dentro de uma mesma série histórica. Essa escolha foi adotada por conta da Resolução CVM 175 que trouxe mudanças na identificação entre CNPJ dos Fundos e das classes dos Fundos.

As variáveis principais do informe diário foram DT_COMPTC, VL_QUOTA, VL_PATRIM_LIQ, CAPTC_DIA, RESG_DIA, NR_COTST e VL_TOTAL. As principais variáveis de cadastro e atributos foram Classificacao, Situacao, Classificacao_Anbima, Publico_Alvo, Exclusivo, Data_Registro, Data_Constituicao e Data_Inicio.

O dicionário completo, com todas as descrições está disponível no repositório.

5. Regras de limpeza, calendário e inclusão/exclusão

5.1 Consolidação e limpeza

A base consolidada passou por padronização de CNPJ, conversão robusta de datas, criação da chave ENTITY_KEY, deduplicação por ENTITY_KEY e DT_COMPTC, e merge com o cadastro da CVM.

Na deduplicação do informe diário, foi mantida uma linha por entidade e data, com preferência para TP_FUNDO_CLASSE = CLASSES - FIF quando havia duplicidade. Também foi registrado o número de conflitos detectados entre linhas duplicadas.

5.2 Calendário B3 e dias válidos

Para tratamento de feriados, foi adotada uma lista de feriados de negociação da B3 para os anos cobertos pela nossa amostra de dados. Com isso, datas sem pregão foram removidas da base de escopo antes da modelagem.

Além disso, foi calculado um indicador de cobertura temporal por entidade:

$\text{valid_day_ratio} = \text{dias \acute{u}teis observados} / \text{dias \acute{u}teis esperados no intervalo da s\acute{e}rie}$

Os critérios adicionais de inclusão foram mínimo de 50 dias úteis válidos e valid_day_ratio maior ou igual a 0,80.

Os resultados observados após o filtro foram: non_business_rows_removed = 14.689; median_valid_day_ratio = 1,0; p05_valid_day_ratio = 0,9979.

5.3 Escopo final

O universo final foi definido como classe Ações, situação Em Funcionamento Normal, mínimo de 50 observações ou dias úteis válidos por entidade e valid_day_ratio maior ou igual a 80%.

6. Construção do target

O target foi definido em duas etapas. Primeiro, calculamos `target_flow_t1_t21` como a soma futura de `CAPTC_DIA` menos `RESG_DIA` entre T+1 e T+21 dias úteis. Depois, esse valor foi normalizado por `pl_lag1`, que representa o patrimônio líquido defasado em 1 dia, resultando em `target_flow_pct_t1_t21`.

Essa definição segue diretamente o case e evita circularidade ao usar patrimônio contemporâneo. Para regressão, também foi construída uma versão clipada, `target_flow_pct_t1_t21_clipped`, limitada ao intervalo `[-1, 1]`. Como apoio para extensões futuras, foi criada a variável `target_top_decile`, indicador binário para observações no decil superior do target por data.

7. Anti-vazamento

Todas as features foram calculadas usando apenas informação disponível até T-1, com defasagem mínima de 1 dia útil. Retornos, volatilidades, drawdowns e sinais de fluxo usam apenas histórico passado. O target usa somente a janela futura T+1:T+21. A validação foi feita com splits temporais e walk-forward, sem shuffle aleatório. Essa regra foi central no desenho da pipeline e foi preservada em todas as fases.

8. Construção de features

As features foram organizadas em blocos alinhados ao case.

No bloco de retornos via `VL_QUOTA`, foram construídas `ret_5d`, `ret_21d`, `ret_63d`, `ret_126d`, `ret_21d_rel_class` e `ret_63d_rel_class`.

No bloco de risco e estabilidade, foram construídas `vol_21d`, `vol_63d`, `drawdown_63d`, `drawdown_126d` e `ret_zscore_21d`.

No bloco de tamanho e momento, foram construídas `log_pl_lag1`, `log_vl_total_lag1`, `log_nr_cotst_lag1`, `ex_flow_return_5d_mean`, `ex_flow_return_21d_mean` e `ex_flow_return_63d_mean`.

No bloco de fluxo e mudança recente de PL, foram construídas `flow_pct_5d_sum`, `flow_pct_21d_sum`, `flow_pct_63d_sum`, `flow_pct_21d_rel_class` e `nr_cotst_change_21d`.

No bloco de sazonalidade, foram construídas `weekday`, `month`, `is_month_end`, `is_quarter_end` e `is_january`.

No bloco de idade e perfil do fundo, foram construídas `fund_age_years`, `anbima_bucket`, `publico_alvo_bucket`, `exclusivo_flag` e `valid_day_ratio`.

9. Tratamento de outliers

O tratamento de outliers foi concentrado nos pontos de maior distorção do problema: filtro de `pl_lag1` maior ou igual a R\$ 1 milhão, exigência de cobertura temporal mínima e clipping do target de regressão em `[-1, 1]`.

Essa abordagem foi escolhida para reduzir a influência desproporcional de fundos muito pequenos e observações extremas, o intuito é manter o pipeline simples e defensável para o escopo do case. Não foi aplicada uma política complexa de winsorização em todas as features, por opção metodológica de evitar excesso de complexidade nesta etapa, por entender que isso fugiria do propósito principal do case.

10. Amostra final

Na base de escopo, os números finais foram: `rows_after_scope_filter` = 1.740.227; `rows_model_ready` = 1.654.531; `eligible_entities` = 3.887; `eligible_class_cnpjs` = 3.826; período de 02/05/2024 a 10/04/2026.

Na base de features e modelagem, os números finais foram: `rows` = 1.185.572; `entities` = 3.725; período de 29/10/2024 a 11/03/2026.

11. Estratégia de validação temporal

O desenho final combinou holdout temporal e walk-forward.

No holdout final, os períodos foram: treino de 29/10/2024 a 08/10/2025; validação de 09/10/2025 a 08/12/2025; teste de 09/12/2025 a 11/03/2026.

No walk-forward, o Fold 1 usou treino de 29/10/2024 a 11/08/2025 e avaliação de 12/08/2025 a 08/10/2025. O Fold 2 usou treino de 29/10/2024 a 08/10/2025 e avaliação de 09/10/2025 a 08/12/2025.

12. Modelo e métricas

O modelo utilizado foi um baseline de regressão com HistGradientBoostingRegressor, aplicado sobre uma matriz de features numéricas e categóricas.


No holdout final, o baseline ficou em MAE = 0,03459 e RMSE = 0,10152. O modelo ficou em MAE = 0,03752 e RMSE = 0,09859.

Na validação, o baseline ficou em MAE = 0,03574 e RMSE = 0,10258. O modelo ficou em MAE = 0,03783 e RMSE = 0,09779.

A interpretação dessas métricas é que o modelo não superou o baseline ingênuo em MAE, o que é compatível com um target altamente concentrado em zero. Por outro lado, houve melhora consistente em RMSE, sugerindo que as features capturam melhor os casos com variações mais intensas de fluxo futuro. Assim, o baseline atual deve ser visto como evidência de sinal preditivo, e não como solução final otimizada.

13. Interpretabilidade e sanity checks

As importâncias por permutation importance destacaram flow_pct_63d_sum, ex_flow_return_5d_mean, ret_5d, vol_63d, flow_pct_5d_sum, log_nr_cotst_lag1, log_pl_lag1, publico_alvo_bucket, anbima_bucket e valid_day_ratio.



Os sanity checks executados incluíram conferência da coerência do target, verificação da concentração do target em zero, validação manual de 2 fundos por 3 datas no bruto, verificação de cobertura temporal por entidade e comparação entre baseline de mediana e modelo final.

13.1 Validação Manual

Esses prints foram tirados do “inf_diario_fi_202405.csv”, onde temos a informação bruta fornecida pela CVM.

A	B	C	D	E	F	G	H	I	J
TP_FUNDO_CLAS	CNPJ_FUNDO_CLAS	ID_SUB	DT_COMP	VL_TOTAL	VL_QUOTA	VL_PATRIM_LIQ	CAPTC_DIA	RESG_DIA	NR_COTST
FI	10.199.934/0001-58		03/05/2024	18719488.76	3.273.720.000.000	19143694.83	17815.98	7571.73	650
FI	10.199.934/0001-58		06/05/2024	18631921.01	3.270.130.000.000	19120653.74	100.00	2140.26	649
FI	10.199.934/0001-58		07/05/2024	18621650.51	3.273.450.000.000	19133164.50	200.00	7136.17	646

A	B	C	D	E	F	G	H	I	J
TP_FUNDO_CLAS	CNPJ_FUNDO_CLAS	ID_SUB	DT_COMP	VL_TOTAL	VL_QUOTA	VL_PATRIM_LIQ	CAPTC_DIA	RESG_DIA	NR_COTST
FI	10.141.924/0001-61		03/05/2024	1068468086.03	2.687.891.600.000	1068141033.85	0.00	0.00	1
FI	10.141.924/0001-61		06/05/2024	1064532851.26	2.677.972.200.000	1064199154.61	0.00	0.00	1
FI	10.141.924/0001-61		07/05/2024	1065687753.19	2.680.960.500.000	1065386661.89	0.00	0.00	1

***Obs: Ao abrir o CSV pelo excel, deu um erro de formatação no valor de VL_QUOTA.**

Agora estes dois prints são referentes a informação coletada do arquivo “manual_validation_samples.json”. Apenas copieie e cole em uma planilha, para que a visualização aqui fosse melhor.

	A	B	C	D	E	F
1	CNPJ_FUNDO_CLAS	DT_COMPT	VL_QUO	VL_PATRIM_LI	CAPTC_D	RESG_D
2	10.199.934/0001-58	03/05/2024	3.27372	19143694.83	17815.98	7571.73
3	10.199.934/0001-58	06/05/2024	3.27013	19120653.74	100.0	2140.26
4	10.199.934/0001-58	07/05/2024	3.27345	19133164.5	200.0	7136.17
5						

	A	B	C	D	E	F
1	CNPJ_FUNDO_CLAS	DT_COMPT	VL_QUOTA	VL_PATRIM_LIQ	CAPTC_D	RESG_D
2	10.141.924/0001-61	03/05/2024	2.6878916	1068141033.85	0	0
3	10.141.924/0001-61	06/05/2024	2.6779722	1064199154.61	0	0
4	10.141.924/0001-61	07/05/2024	2.6809605	1065386661.89	0	0
8						

Com isso, vemos que a informação corresponde perfeitamente.

14. Principais conclusões

Os resultados sugerem que o fluxo futuro em fundos de ações é influenciado por persistência de fluxo recente, retorno e retorno ex-flow recentes, volatilidade e estabilidade, tamanho do fundo e base de cotistas, além do perfil do produto e do investidor.

O problema permanece difícil, mas o pipeline mostra que há sinal preditivo economicamente plausível nas variáveis construídas. O ganho em RMSE reforça que o modelo melhora a captura das observações mais intensas, mesmo sem superar o baseline em MAE.

15. Limitações e próximos passos

As principais limitações foram target muito concentrado em zero, presença de caudas extremas, cobertura incompleta de parte do cadastro e ausência de variáveis externas de mercado.

Como próximos passos, faria sentido testar a formulação em classificação usando top-decile, experimentar losses ou modelos mais robustos para caudas, aprofundar análise por subgrupos, ampliar a comparação entre versões de tratamento de outliers e refinar a camada visual para o estudo executivo.

16. Nota sobre uso de IA

Este case contou com apoio pontual de ferramentas de IA, especificamente o Codex da OpenAI, principalmente para diagnóstico de erros, correção de bugs, revisão textual e apoio em trechos de implementação. As decisões metodológicas, a validação dos resultados, a definição do pipeline e a responsabilidade final sobre o conteúdo e as conclusões permaneceram sob minha supervisão.