

ESTUDO PADRÃO

Drivers de captação líquida futura em fundos de ações com dados públicos da CVM

1. Contexto e pergunta

Este estudo investiga quais sinais observáveis até a data T ajudam a explicar a captação líquida futura de entidades da classe Ações em funcionamento normal, usando exclusivamente dados públicos da CVM. A pergunta central foi: fundos com melhor desempenho recente, menor risco e maior estabilidade tendem a captar mais nos 21 dias úteis seguintes?

A base foi construída a partir do Informe Diário de Fundos e do cadastro de classes da CVM, cobrindo aproximadamente 24 meses, de 02/05/2024 a 10/04/2026. O universo analisado incluiu apenas fundos com Classificação = Ações e Situação = Em Funcionamento Normal. Como critério adicional de qualidade, foram mantidas apenas entidades com pelo menos 50 dias úteis válidos, `valid_day_ratio` igual ou superior a 80% em relação ao calendário de negociação da B3 e PL defasado mínimo de R\$ 1 milhão na etapa final de modelagem.

O target foi definido como o fluxo líquido futuro acumulado entre T+1 e T+21 dias úteis, calculado por `CAPTC_DIA` menos `RESG_DIA` e normalizado pelo PL defasado em 1 dia. A formulação principal escolhida foi regressão, porque o alvo é contínuo e preservar sua magnitude ajuda mais a entender a intensidade esperada de captação ou resgate do que apenas separar eventos extremos em uma classe binária. A validação foi feita com splits temporais, sem embaralhamento aleatório, combinando um holdout temporal final com janelas de walk-forward.

2. Amostra e janelas

A base consolidada do informe diário gerou mais de 12,4 milhões de linhas, com tratamento de datas, padronização de CNPJ, deduplicação por entidade e data e merge com o cadastro. A granularidade adotada foi `ENTITY_KEY = CNPJ_FUNDO + ID_SUBCLASSE`, evitando misturar subclasses distintas dentro da mesma série histórica.

Com a introdução explícita do calendário B3, foram removidas 14.689 linhas em datas sem negociação. Ainda assim, a cobertura dos fundos remanescentes ficou alta: a mediana de `valid_day_ratio` foi 1,0 e o percentil 5 ficou em 0,9979. Após o filtro da classe Ações, a base ficou com 1.740.227 linhas e 3.887 entidades elegíveis.

Depois da construção das features históricas, da exigência de janelas completas e dos filtros finais de modelagem, a amostra usada no baseline ficou em 1.185.572 linhas, cobrindo 3.725 entidades, no período de 29/10/2024 a 11/03/2026. Os splits temporais finais foram: treino de 29/10/2024 a 08/10/2025, validação de 09/10/2025 a 08/12/2025 e teste de 09/12/2025 a 11/03/2026. A validação manual exigida no case também foi realizada para 2 fundos e 3 datas por fundo, com conferência direta no bruto dos campos

CAPTC_DIA, RESG_DIA, VL_PATRIM_LIQ e VL_QUOTA.

3. Principais drivers

Os sinais que mais apareceram como explicativos no baseline atual foram fluxo passado acumulado, especialmente em 63 e 21 dias, retorno ex-flow recente, retorno recente, volatilidade recente, tamanho do fundo, número de cotistas e perfil do investidor.

A principal leitura é que fluxo recente é o sinal mais forte para fluxo futuro, sugerindo persistência comercial e comportamental. Em seguida, aparecem variáveis ligadas à qualidade recente do desempenho e ao nível de risco, o que é coerente com a ideia de que investidores e distribuidores respondem a fundos que performam bem e mantêm trajetória mais estável. Tamanho e perfil do produto também ajudam a explicar diferenças de comportamento entre fundos.

As variáveis mais relevantes no holdout foram `flow_pct_63d_sum`, `ex_flow_return_5d_mean`, `ret_5d`, `vol_63d`, `flow_pct_5d_sum`, `log_nr_cotst_lag1`, `log_pl_lag1`, `publico_alvo_bucket` e `anbima_bucket`.

4. Implicações práticas

Do ponto de vista prático, os resultados sugerem que a captação futura de fundos de ações é influenciada por uma combinação de persistência de fluxo recente, desempenho recente, risco e volatilidade, porte e perfil comercial do fundo. Isso indica que uma rotina simples de monitoramento já poderia capturar sinais úteis para antecipar fluxos, usando informações públicas e atualizadas com frequência. Em especial, fundos com melhor dinâmica recente de fluxo e retorno tendem a mostrar comportamento futuro mais favorável, enquanto fundos mais voláteis ou com trajetória mais instável parecem enfrentar maior dificuldade de captação.

5. Limitações e próximos passos

O problema é difícil porque o target é fortemente concentrado em zero, com caudas relevantes. Isso faz com que um baseline ingênuo de mediana seja competitivo em MAE. No holdout final, o baseline simples ficou em $MAE = 0,0346$ e $RMSE = 0,1015$, enquanto o modelo ficou em $MAE = 0,0375$ e $RMSE = 0,0986$. A leitura é que o modelo agrega valor principalmente nos casos de fluxo mais intenso, mas ainda não supera o baseline em erro absoluto médio.

As principais limitações deste estudo são a forte concentração do target em zero, a presença de caudas extremas, a cobertura incompleta de parte das metadata do cadastro e a ausência de variáveis externas de mercado. Como próximos passos, faria sentido testar também a formulação em classificação para top decile de `flow_%` futuro, explorar modelos mais robustos para caudas e assimetria, aprofundar a análise por subgrupos e ampliar a camada visual do estudo com gráficos de quantis e comparações por perfil de fundo.